

PROPOSTA DE TRABALHO DE CONCLUSÃO DE CURSO

Visualização Interativa de Dados Educacionais

Análise de fatores associados ao desempenho das escolas públicas brasileiras

Curso: Sistemas de Informação

Área: Visualização de Dados

Tecnologias centrais: D3.js e DuckDB-Wasm

1. Objetivo

Desenvolver uma aplicação web de visualização interativa de dados, utilizando **D3.js** e **DuckDB-Wasm**, que permita explorar relações entre o desempenho educacional das escolas públicas brasileiras (**Ideb**) e suas características de infraestrutura e recursos tecnológicos (**Censo Escolar**).

O trabalho terá caráter **exploratório e observacional**, tendo como objetivo possibilitar a identificação visual de padrões e associações entre os dados, **sem estabelecer relações de causalidade**.

2. Bases de Dados

As duas bases abaixo formam o núcleo de dados do projeto. Ambas são públicas, oficiais, mantidas pelo Inep, e já foram identificadas e verificadas quanto à disponibilidade e ao formato.

Base	O que fornece	Uso no projeto
Censo Escolar	Infraestrutura, matrículas, localização e recursos tecnológicos de cada escola, incluindo código Inep, computadores, acesso à internet, laboratórios, entre outros.	Variáveis de análise, utilizadas principalmente no eixo X das visualizações.
Ideb	Indicador de desempenho educacional por escola, rede e etapa de ensino.	Indicador de desempenho, utilizada principalmente no eixo Y das visualizações.

As duas bases são **relacionáveis diretamente pelo código Inep da escola**, o que garante a viabilidade técnica de integração dos dados.

Essa integração já foi verificada: ambas utilizam essa chave e estão disponíveis para download em formato aberto no portal do Inep.

Extensão opcional

Caso o cronograma permita, o Indicador de Nível Socioeconômico (Inse) poderá ser incorporado como uma terceira dimensão de análise, também relacionável pelo mesmo código da escola.

Essa base será considerada opcional e não será necessária para a entrega principal do projeto.

3. Tecnologias

- Python + Pandas** — extração, limpeza, padronização e integração das duas bases pelo código Inep (ETL), gerando um CSV único e tratado (equivalente ao papel do ETL.py no projeto de referência).
- DuckDB-Wasm** — motor analítico SQL executado diretamente no navegador. Carrega o CSV tratado, materializa uma tabela tipada (com TRY_CAST/TRY_STRPTIME para tolerar

sujeira residual) e responde às consultas (SELECT/WHERE/GROUP BY) que alimentam cada visualização, eliminando a necessidade de backend ou banco de dados dedicado.

- **HTML, CSS e JavaScript** — estrutura da aplicação web.
- **D3.js** — biblioteca principal utilizada para a construção das visualizações interativas, consumindo os resultados das consultas SQL do DuckDB.

Extração → Tratamento (Pandas) → Integração (DuckDB) → Visualização ([D3.js](#))

4. Justificativa e Proposta de Design

4.1 Por que esses dados são desafiadores?

A análise de dados educacionais brasileiros apresenta desafios que vão além do processamento técnico das bases. Em primeiro lugar, existe um forte efeito de confundimento entre infraestrutura tecnológica e nível socioeconômico: escolas com mais recursos tecnológicos tendem a estar em regiões mais favorecidas, que já apresentam Ideb mais alto por múltiplos fatores independentes da tecnologia em si. Isso exige que o sistema seja desenhado para permitir comparações dentro de contextos semelhantes (mesma rede, mesma região, etapa de ensino equivalente), evitando que o usuário interprete associação como causalidade.

Em segundo lugar, há heterogeneidade estrutural entre as unidades de análise: comparar diretamente uma escola rural do Norte com uma urbana do Sul, sem considerar o contexto, pode levar a conclusões enganosas. Some-se a isso o fato de que escolas pequenas apresentam indicadores de desempenho mais instáveis, já que o Ideb calculado sobre poucos alunos é estatisticamente mais ruidoso.

Por fim, o próprio tratamento das bases é desafiador: o Censo Escolar e o Ideb apresentam inconsistências e dados ausentes entre edições, exigindo uma etapa cuidadosa de limpeza e padronização antes da integração pelo código Inep, que é o núcleo técnico do projeto descrito na seção anterior.

4.2 Perguntas que o sistema pretende responder

O sistema foi desenhado para permitir que o usuário explore, de forma guiada, as seguintes questões:

1. Escolas com maior disponibilidade de infraestrutura tecnológica (computadores por aluno, acesso à internet, laboratórios) apresentam Ideb sistematicamente maior quando comparadas dentro do mesmo contexto socioeconômico e de rede de ensino?
2. Existe um ponto de saturação de infraestrutura tecnológica, a partir do qual investimentos adicionais não parecem associados a ganhos de desempenho?
3. Como essa associação varia entre redes de ensino (municipal, estadual, federal) e entre etapas de ensino (anos iniciais, anos finais, ensino médio)?
4. Quais escolas apresentam desempenho muito acima ou muito abaixo do esperado dado seu nível de infraestrutura, e o que esses casos de destaque (outliers) sugerem sobre fatores não capturados pelos dados disponíveis?
5. Como a relação entre infraestrutura e desempenho evolui ao longo das edições disponíveis do Censo Escolar e do Ideb?

Essas perguntas orientam diretamente o design das visualizações descrito a seguir: cada view do sistema foi concebida para responder a uma ou mais delas.

4.3 Proposta de design da interface

O sistema foi estruturado como um dashboard de página única, com views coordenadas por cross-filter, seguindo o princípio de exploração de dados "visão geral primeiro, filtro e zoom, detalhe sob demanda" (Shneiderman, 1996). A interface é organizada em três níveis:

Nível 1 — Panorama geográfico. Um mapa coroplético do Brasil, com as unidades federativas coloridas de acordo com o Ideb médio, construído a partir de uma malha TopoJSON real das UFs (derivada dos shapefiles do IBGE). Este nível responde à motivação do projeto ao evidenciar visualmente a desigualdade regional de desempenho educacional, servindo como ponto de entrada para a exploração.

Nível 2 — Relação entre infraestrutura e desempenho. Um gráfico de dispersão no qual cada ponto representa uma escola, com o Ideb no eixo Y e uma variável de infraestrutura selecionável no eixo X, colorido por rede de ensino. Este nível é o núcleo analítico do sistema, respondendo diretamente às perguntas 1, 2 e 3: a possibilidade de trocar a variável do eixo X e aplicar filtros permite investigar saturação e variação entre redes sem exigir telas separadas.

Nível 3 — Detalhamento e comparação. A seleção de pontos no gráfico de dispersão (via brush) ou de itens em um painel de outliers popula uma área de comparação entre escolas selecionadas, respondendo à pergunta 4.

As três visões permanecem sempre visíveis e coordenadas: uma interação em qualquer uma delas — selecionar um estado no mapa, trocar a variável do eixo X, fazer brush no scatter, clicar em um outlier — dispara uma nova consulta SQL no DuckDB que atualiza as demais views simultaneamente. Filtros persistentes (estado, rede, etapa de ensino, ano) permanecem visíveis durante toda a navegação, permitindo que o usuário refine progressivamente sua análise sem perder o contexto.

Essa arquitetura de views coordenadas é o que diferencia o sistema proposto de um conjunto estático de gráficos: cada interação refina uma pergunta analítica específica, e não apenas um filtro estético sobre os dados.

5. Como será feito

Etapa 1 — Tratamento e integração dos dados

- Download dos microdados do Censo Escolar e dos resultados do Ideb, considerando as edições mais recentes disponíveis.
- Limpeza e padronização dos dados com Pandas (tipos, valores ausentes, nomes de colunas).
- Junção das duas bases pelo código Inep da escola, considerando também ano e etapa de ensino quando necessário.
- Seleção das variáveis relevantes para a análise.
- Cálculo de indicadores derivados, como computadores por aluno.
- Exportação do resultado como um CSV único e tratado, que servirá de entrada para o DuckDB-Wasm no navegador.

Etapa 2 — Análise exploratória

Será realizada uma análise estatística descritiva do conjunto de dados integrado, buscando identificar quais variáveis de infraestrutura e tecnologia apresentam maior associação com o Ideb. Essa etapa poderá ser feita tanto em Python quanto diretamente via consultas SQL no DuckDB, aproveitando a mesma tabela que alimentará a aplicação.

Essa etapa servirá para definir quais variáveis possuem maior relevância e, consequentemente, quais devem ser priorizadas nas visualizações.

A análise terá caráter observacional e não terá como objetivo afirmar que determinada característica causa aumento ou redução do Ideb.

Etapa 3 — Carga dos dados no DuckDB-Wasm

Em vez de pré-gerar arquivos **JSON** fixos para cada gráfico, o CSV tratado na Etapa 1 será carregado no navegador pelo **DuckDB-Wasm**. Um script SQL (`CREATE OR REPLACE TABLE`) materializa apenas as colunas necessárias, já tipadas (`INTEGER`, `DOUBLE`, `VARCHAR`), descartando o restante do schema bruto.

Isso permite que as visualizações consultem os dados sob demanda com SQL (filtros, agregações, contagens) em vez de depender de arquivos estáticos pré-calculados para cada combinação de filtro.

Etapa 4 — Desenvolvimento das visualizações

A aplicação web contará com visualizações interativas que permitam explorar os dados de forma dinâmica, com cross-filter entre elas: uma interação em uma visão (ex.: selecionar um estado) refina, via nova consulta ao DuckDB, os dados exibidos nas demais.

Entre as visualizações previstas estão:

- **Gráfico de dispersão:** relação entre Ideb e variáveis de infraestrutura ou tecnologia.
- **Matriz de correlação:** comparação entre o Ideb e as variáveis selecionadas.
- **Comparação entre escolas:** possibilidade de selecionar escolas e comparar seus indicadores.
- **Filtros interativos:** seleção por estado, rede de ensino, etapa de ensino e outras dimensões relevantes, traduzidos em cláusulas `WHERE` reaplicadas a cada consulta.

As visualizações poderão ser ajustadas após a análise exploratória, priorizando aquelas que apresentarem maior potencial para revelar padrões nos dados.

Etapa 5 — Avaliação

A aplicação pode vir a ser testada com um pequeno grupo de usuários, buscando verificar se as visualizações permitem:

- compreender os indicadores apresentados;
- identificar padrões e tendências;
- comparar diferentes escolas ou grupos de escolas;
- utilizar os filtros e recursos interativos de forma intuitiva;
- interpretar corretamente as informações apresentadas.

6. Viabilidade do Projeto

As duas bases de dados que formam o núcleo do projeto — **Censo Escolar e Ideb** — já foram identificadas, verificadas quanto à disponibilidade pública e confirmadas como relacionáveis por meio do **código Inep da escola**.

Dessa forma, a etapa de obtenção e integração dos dados, que representa uma das principais incertezas em projetos dessa natureza, apresenta viabilidade técnica comprovada desde o início do trabalho.

A adoção do DuckDB-Wasm mantém a arquitetura do projeto simples — sem backend, servidor de banco de dados ou API dedicados —, ao mesmo tempo em que dá às visualizações mais flexibilidade do que arquivos JSON pré-calculados, já que qualquer nova consulta SQL pode ser feita sob demanda, no próprio navegador, sobre a tabela já carregada. Os esforços permanecem concentrados no tratamento dos dados, na análise exploratória e no desenvolvimento das visualizações interativas com [D3.js](#).

7. Links para as bases de dados

Seguem os links para as bases de dados que pretendemos utilizar no projeto:

Dados do Censo Escolar:

<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/censo-escolar>

Dados do IDEB:

<https://www.gov.br/inep/pt-br/areas-de-atuacao/pesquisas-estatisticas-e-indicadores/ideb/resultados>

Dados do INSE (extensão possível):

<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/indicadores-educacionais/nivel-socioeconomico>